

LAPORAN TEKNIS

Sistem Prediksi Penyakit Diabetes

Berbasis Machine Learning

DiabetesSense — ML Classifier

Mata Kuliah : Pembelajaran Mesin

Semester : Genap 2025/2026

Universitas : Universitas Dian Nuswantoro (UDINUS) Semarang

Anggota 1 : Fahmi Fatmawati Azzahra — NIM: A11.2024.15831

Anggota 2 : Nathaniela Febry Nathasa — NIM: A11.2024.15850

Dosen Pengampu : Prof. Ir. Heru Agus Santoso, Ph.D, IPM, ASEAN Eng.

DAFTAR ISI

1. Pendahuluan & Latar Belakang
2. Metodologi
3. Hasil dan Analisis
4. Deployment & Antarmuka Aplikasi
5. Kesimpulan dan Rekomendasi
6. Referensi

1. Pendahuluan & Latar Belakang

1.1 Latar Belakang

Diabetes mellitus adalah penyakit metabolik kronis yang ditandai oleh hiperglikemia (kadar glukosa darah tinggi) akibat gangguan sekresi atau kerja insulin. Berdasarkan data *International Diabetes Federation* (IDF) edisi 2021, terdapat sekitar **537 juta** orang dewasa yang hidup dengan diabetes di seluruh dunia. Di Indonesia, Risesdas 2018 mencatat prevalensi diabetes pada penduduk ≥ 15 tahun sebesar 10,9%, meningkat dari 6,9% pada 2013.

Pendekatan *Machine Learning* menawarkan solusi inovatif untuk deteksi dini diabetes melalui analisis pola pada data rekam medis. Dengan parameter kesehatan dasar seperti kadar glukosa, BMI, tekanan darah, dan usia, model ML dapat mengklasifikasikan pasien berisiko tinggi secara otomatis dan efisien.

1.2 Problem Statement

Permasalahan: Bagaimana membangun model Machine Learning yang mampu memprediksi apakah seorang pasien perempuan keturunan Pima Indian berusia ≥ 21 tahun menderita diabetes, berdasarkan parameter diagnostik kesehatan yang tersedia?

Jenis Task: Binary Classification (0 = Tidak Diabetes, 1 = Diabetes)

1.3 Tujuan

- Membangun dan membandingkan minimal 3 model Machine Learning untuk prediksi diabetes
- Mengidentifikasi faktor-faktor risiko yang paling berpengaruh terhadap diabetes
- Mengembangkan aplikasi web interaktif untuk skrining awal diabetes
- Mendokumentasikan seluruh proses pipeline ML secara komprehensif

1.4 Metrik Kesuksesan

Metrik	Target Minimum	Alasan
Accuracy	$\geq 75\%$	Benchmark performa umum
F1-Score	$\geq 0,70$	Menyeimbangkan Precision & Recall
AUC-ROC	$\geq 0,80$	Kemampuan diskriminasi kelas
Recall	$\geq 0,75$	Meminimalkan false negative (bahaya medis)

1.5 Dataset

Nama: Pima Indians Diabetes Database

Institusi: National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK), USA


Akses Publik: UCI Machine Learning Repository & Kaggle

Informasi	Detail
Jumlah Sampel	768
Jumlah Fitur Input	8
Target	Outcome (0 = Tidak DM, 1 = DM)
Populasi	Perempuan keturunan Pima Indian, ≥ 21 tahun

Format	CSV (comma-separated values)
--------	------------------------------

2. Metodologi

2.1 Alur Kerja (Pipeline)



2.2 Data Acquisition

Dataset diunduh dari repository publik GitHub (Jason Brownlee's Datasets). Verifikasi keaslian dilakukan dengan membandingkan statistik deskriptif dengan dokumentasi resmi UCI Machine Learning Repository.

2.3 Exploratory Data Analysis (EDA)

EDA mencakup: (a) analisis kualitas data — missing values eksplisit, implicit missing (nilai 0 tidak valid medis), dan duplikat; (b) analisis univariat — distribusi histogram per kelas; (c) analisis multivariat — korelasi Pearson dan scatter plots.

Tabel 2.1 — Implicit Missing Values (Nilai 0 Tidak Valid)

Kolom	Jumlah Nilai 0	Persentase
Glucose	5	0,7%
BloodPressure	35	4,6%
SkinThickness	227	29,6%
Insulin	374	48,7%
BMI	11	1,4%

2.4 Preprocessing

- **Penanganan Missing Values:** Nilai 0 pada 5 kolom diganti NaN, lalu diimputasi dengan median per kelas (stratified median imputation).
- **Feature Engineering:** 4 fitur baru: BMI_Category, Glucose_Category, Age_Group, Insulin_Glucose_Ratio.
- **Pembagian Dataset:** Stratified split: Train 70% (537), Validation 15% (115), Test 15% (116).
- **Feature Scaling:** StandardScaler di-fit hanya pada training set untuk mencegah data leakage.

2.5 Pemodelan & Hyperparameter Tuning

Model	Deskripsi	Grid Parameter Utama
Logistic Regression	Baseline linear, interpretabilitas koefisien tinggi	C=[0.01,0.1,1,10,100], solver=[lbfgs, liblinear]
Random Forest	Ensemble bagging, robust terhadap overfitting	n_estimators=[100,200,300], max_depth=[None,10,20]
Gradient Boosting	Ensemble boosting sekuensial, umumnya terbaik pada tabe	n_estimators=[100,200,300], lr=[0.05,0.1,0.15]

Tuning menggunakan GridSearchCV dengan 5-fold Stratified K-Fold dan scoring F1-Score.

3. Hasil dan Analisis

3.1 Hasil EDA

Analisis korelasi Pearson menunjukkan **Glucose** memiliki korelasi tertinggi dengan target Outcome ($r \approx 0,47$), diikuti **BMI** ($r \approx 0,29$), **Age** ($r \approx 0,24$), dan **Pregnancies** ($r \approx 0,22$). Dataset menunjukkan **class imbalance** 65:35 yang ditangani dengan `class_weight="balanced"`.

3.2 Hasil Training & Evaluasi

Berikut performa ketiga model pada **Test Set** (data yang belum pernah dilihat selama training):

Model	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Logistic Regression	0,7586	0,6250	0,7500	0,6818	0,8283
Random Forest	0,8793	0,7955	0,8750	0,8333	0,9482
Gradient Boosting ■	0,8966	0,8333	0,8750	0,8537	0,9582

Tabel 3.1 — Perbandingan Performa Model (Test Set). ■ = Model Terbaik

3.3 Model Terbaik: Gradient Boosting

Gradient Boosting dipilih sebagai model terbaik berdasarkan F1-Score tertinggi pada validation set (0,8571). Model ini memberikan keseimbangan terbaik antara Precision (0,8333) dan Recall (0,8750), dengan AUC-ROC 0,9582 — artinya model mampu membedakan kelas diabetes dan non-diabetes dengan sangat baik (95,82%).

3.4 Feature Importance

Ranking	Fitur	Nilai Importance (GB)	Interpretasi
1	Insulin	0,6879	Kadar insulin paling dominan dalam prediksi
2	Glucose	0,1082	Gula darah sangat berkorelasi dengan DM
3	Age	0,0712	Usia meningkatkan risiko diabetes
4	SkinThickness	0,0350	Proxy ketebalan lemak tubuh
5	BMI	0,0347	Indeks massa tubuh terkait obesitas

Tabel 3.2 — Top 5 Feature Importance (Gradient Boosting)

4. Deployment & Antarmuka Aplikasi

4.1 Teknologi Deployment

Aplikasi **DiabetesSense** dibangun menggunakan teknologi open-source dan di-deploy ke platform cloud gratis sehingga dapat diakses dari mana saja tanpa instalasi apapun.

Komponen	Teknologi	Fungsi
Web Framework	Streamlit 1.x	Membangun antarmuka web interaktif berbasis Python
Hosting	Streamlit Community Cloud	Platform hosting gratis, auto-deploy dari GitHub
Source Control	GitHub	Version control, penyimpanan kode & model .pkl
ML Library	Scikit-learn	Training, evaluasi, dan serialisasi model ML
Visualisasi	Plotly	Grafik interaktif (bar, pie, heatmap, radar, ROC)
Serialisasi	Joblib	Menyimpan dan memuat model yang telah dilatih

Tabel 4.1 — Tech Stack Deployment Aplikasi

4.2 Arsitektur Aplikasi

Aplikasi DiabetesSense terdiri dari **6 halaman** yang dapat diakses melalui sidebar navigasi di sisi kiri layar. Setiap halaman dirancang untuk tujuan yang spesifik dan saling melengkapi.

No.	Halaman	Fungsi Utama
1	■ Beranda	Informasi tim pengembang, statistik dataset, latar belakang proyek, dan alur pipeline ML
2	■ EDA Dashboard	Eksplorasi data interaktif: distribusi fitur, korelasi antar variabel, kualitas data, dan 5 key insights
3	■ Prediksi Diabetes	Form input data pasien → prediksi real-time dengan probabilitas + analisis faktor risiko personal
4	■ Evaluasi Model	Tabel perbandingan 3 model, confusion matrix interaktif, ROC curves, dan radar chart performa
5	■ Interpretasi & Bisnis	Feature importance per model, justifikasi pemilihan model terbaik, rekomendasi strategis
6	■ Dokumentasi	Deskripsi dataset, metodologi pipeline ML, tech stack, dan panduan penggunaan aplikasi

Tabel 4.2 — Arsitektur Halaman Aplikasi DiabetesSense

4.3 Link Akses Aplikasi

Platform	URL / Link
■ Streamlit App (Live)	https://fahmi-natha-diabetes-ml.streamlit.app/
■ GitHub Repository	https://github.com/Nathanielaiueo/diabetes-ml-project


Tabel 4.3 — Link Akses Aplikasi

4.4 Antarmuka Aplikasi

Berikut adalah tampilan antarmuka dari seluruh halaman utama aplikasi DiabetesSense yang telah berhasil di-deploy dan dapat diakses secara online.

4.4.1 Halaman Beranda


Halaman pembuka menampilkan identitas tim pengembang beserta NIM, statistik ringkas dataset (768 sampel, 8 fitur, 268 kasus DM), latar belakang proyek, dan alur pipeline Machine Learning.



Gambar 4.1 — Halaman Beranda: Tim pengembang, statistik dataset, dan informasi proyek

4.4.2 Halaman EDA Dashboard


EDA Dashboard menyediakan 5 tab eksplorasi data interaktif: Overview (ringkasan dataset & preview tabel), Distribusi & Univariat (histogram per kelas), Korelasi & Multivariat (heatmap & scatter), Kualitas Data (missing values & outlier), dan 5 Key Insights.



Gambar 4.2 — EDA Dashboard: Tab Overview menampilkan ringkasan dataset dan preview data

4.4.3 Halaman Prediksi Diabetes


Halaman prediksi menyediakan form interaktif dengan 8 slider input (Kehamilan, Glukosa, Tekanan Darah, Kulit Triceps, Insulin, BMI, Diabetes Pedigree, Usia). Pengguna dapat memilih model (LR, RF, atau GB) dan mendapatkan hasil prediksi real-time beserta probabilitas, tingkat risiko, dan referensi nilai normal medis.



Gambar 4.3 — Halaman Prediksi: Form input pasien dan hasil prediksi "Tidak Terdeteksi Diabetes"

4.4.4 Halaman Evaluasi Model


Halaman Evaluasi Model menampilkan: (a) kartu metrik model terbaik (Gradient Boosting: Accuracy 89,66%, F1 0,8537, AUC-ROC 0,9582), (b) tabel perbandingan lengkap ketiga model pada Train/Val/Test set, (c) confusion matrix interaktif per model, dan (d) ROC curves serta radar chart perbandingan visual.



Gambar 4.4 — Evaluasi Model: Kartu performa Gradient Boosting dan tabel perbandingan 3 model

4.4.5 Halaman Interpretasi & Insights Bisnis

Halaman ini menyajikan analisis feature importance dari ketiga model, justifikasi pemilihan Gradient Boosting sebagai model terbaik, serta rekomendasi strategis bagi fasilitas kesehatan. Feature terpenting dari Gradient Boosting adalah **Insulin** (0,6879), diikuti Glucose (0,1082) dan Age (0,0712).



Gambar 4.5 — Interpretasi: Feature Importance Gradient Boosting dan justifikasi model terbaik

5. Kesimpulan dan Rekomendasi

5.1 Kesimpulan

1. Semua target metrik berhasil dicapai: Accuracy 89,66% ($\geq 75\%$), F1-Score 0,8537 ($\geq 0,70$), AUC-ROC 0,9582 ($\geq 0,80$), dan Recall 0,8750 ($\geq 0,75$).
2. Insulin dan Glucose adalah prediktor terkuat pada model Gradient Boosting terbaik.
3. Machine Learning terbukti efektif untuk skrining awal diabetes dengan akurasi kompetitif.
4. Gradient Boosting memberikan keseimbangan terbaik antara Precision dan Recall.
5. Aplikasi Streamlit DiabetesSense berhasil dibangun dan di-deploy secara online, dapat diakses tanpa instalasi.

5.2 Rekomendasi

Rekomendasi Klinis / Bisnis:

- Implementasikan sistem skrining ML ini di fasilitas kesehatan primer (puskesmas, klinik)
- Prioritaskan pemeriksaan kadar insulin, glukosa, dan BMI pada setiap kunjungan
- Gunakan threshold prediksi $\geq 0,4$ untuk meminimalkan false negative yang berbahaya

Rekomendasi Teknis:

- Implementasikan SMOTE untuk oversampling minority class secara lebih agresif
- Eksplorasi XGBoost, LightGBM, dan ensemble stacking untuk performa lebih tinggi
- Gunakan SHAP (SHapley Additive exPlanations) untuk interpretabilitas yang lebih mendalam
- Validasi model pada dataset yang lebih besar dan populasi yang lebih beragam

5.3 Keterbatasan

- Dataset terbatas (768 sampel) dari populasi spesifik (perempuan Pima Indian ≥ 21 tahun)
- Validasi eksternal belum dilakukan pada populasi berbeda atau data Indonesia
- Fitur penting seperti HbA1c dan kolesterol tidak tersedia dalam dataset

6. Referensi

- [1] Smith, J.W. et al. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proceedings of SCAMC, 261–265.
- [2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825–2830.
- [3] International Diabetes Federation. (2021). IDF Diabetes Atlas, 10th Edition. Brussels: IDF.
- [4] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.
- [5] Friedman, J.H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. Ann. Stat., 29(5), 1189–1232.
- [6] Hosmer, D.W. & Lemeshow, S. (2000). Applied Logistic Regression (2nd ed.). Wiley.
- [7] James, G. et al. (2021). An Introduction to Statistical Learning (2nd ed.). Springer.
- [8] Streamlit Inc. (2024). Streamlit — The fastest way to build data apps. <https://streamlit.io>
- [9] Kementerian Kesehatan RI. (2018). Hasil Utama Riskesdas 2018. Balitbangkes.
- [10] American Diabetes Association. (2023). Standards of Medical Care in Diabetes. Diabetes Care, 46(S1).

*Laporan ini merupakan bagian dari keluaran wajib UAS Pembelajaran Mesin
Semester Genap 2025/2026 — Teknik Informatika — UDINUS Semarang*