

LAPORAN TEKNIS

UJIAN AKHIR SEMESTER (UAS)

MATA KULIAH PEMBELAJARAN MESIN

*Sistem Prediksi Penyakit Diabetes Berbasis Machine Learning
menggunakan Pima Indians Diabetes Dataset (NIDDK)*

DISUSUN OLEH:

Fahmi Fatmawati Azzahra

NIM: A11.2024.15831

Nathaniela Febry Nathasa

NIM: A11.2024.15850

Mata Kuliah	Pembelajaran Mesin
Semester	Genap 2025/2026
Universitas	Universitas Dian Nuswantoro (UDINUS) Semarang
Program Studi	Teknik Informatika (S1)
Koordinator MK	Ardytha Luthfiarta, M.Kom, MCS
Tanggal	Juli 2026

DAFTAR ISI		
1.	PENDAHULUAN DAN LATAR BELAKANG	3
1.1	Latar Belakang	3
1.2	Rumusan Masalah	3
1.3	Tujuan Penelitian	3
1.4	Metrik Kesuksesan	3
1.5	Deskripsi Dataset	4
2.	METODOLOGI	4
2.1	Alur Kerja (Pipeline)	4
2.2	Data Acquisition	4
2.3	Exploratory Data Analysis	5
2.4	Preprocessing	5
2.5	Pemodelan	6
2.6	Evaluasi	6
3.	HASIL DAN ANALISIS	7
3.1	Hasil EDA	7
3.2	Hasil Preprocessing	7
3.3	Hasil Training & Tuning	7
3.4	Perbandingan Metrik Semua Model	8
3.5	Feature Importance Analysis	8
3.6	Visualisasi	9
4.	KESIMPULAN DAN REKOMENDASI	10
4.1	Kesimpulan	10
4.2	Rekomendasi	10
4.3	Keterbatasan	11
5.	REFERENSI	11

1 PENDAHULUAN DAN LATAR BELAKANG

1.1 Latar Belakang

Diabetes mellitus merupakan penyakit metabolik kronis yang ditandai oleh hiperglikemia (kadar glukosa darah tinggi) akibat gangguan sekresi atau kerja insulin. Berdasarkan data *International Diabetes Federation* (IDF) edisi 2021, terdapat sekitar **537 juta** orang dewasa (usia 20–79 tahun) yang hidup dengan diabetes di seluruh dunia. Angka ini diproyeksikan meningkat menjadi **643 juta** pada 2030 dan **783 juta** pada 2045 — menjadikan diabetes salah satu krisis kesehatan global terbesar abad ke-21.

Di Indonesia, Riset Kesehatan Dasar (Riskesdas) 2018 mencatat prevalensi diabetes pada penduduk usia ≥ 15 tahun sebesar **10,9%**, meningkat signifikan dari 6,9% pada 2013. Penyakit ini menyumbang risiko komplikasi serius: kardiovaskular, gagal ginjal (nefropati diabetik), neuropati perifer, dan retinopati. Deteksi dini terbukti mengurangi komplikasi dan biaya pengobatan secara substansial.

Pendekatan *Machine Learning* menawarkan solusi inovatif untuk deteksi dini melalui analisis pola pada rekam medis. Dengan parameter kesehatan dasar (glukosa, BMI, tekanan darah, usia), model ML dapat mengklasifikasikan risiko diabetes secara otomatis dan efisien, mendukung tenaga kesehatan dalam pengambilan keputusan klinis.

1.2 Rumusan Masalah

Bagaimana membangun model *Machine Learning* yang mampu memprediksi dengan akurat apakah seorang pasien perempuan keturunan Pima Indian berusia ≥ 21 tahun menderita diabetes, berdasarkan parameter diagnostik kesehatan yang tersedia dalam Pima Indians Diabetes Dataset?

1.3 Tujuan Penelitian

- Membangun dan membandingkan minimal 3 model Machine Learning untuk prediksi diabetes.
- Mengidentifikasi faktor-faktor risiko yang paling berpengaruh terhadap kejadian diabetes.
- Mengembangkan aplikasi web interaktif berbasis Streamlit untuk skrining awal.
- Mendokumentasikan seluruh proses pipeline ML secara komprehensif sesuai standar akademik.

1.4 Metrik Kesuksesan

Metrik	Target Minimum	Alasan
Accuracy	$\geq 75\%$	Benchmark performa klasifikasi umum
F1-Score	≥ 0.70	Menyeimbangkan Precision & Recall pada data imbalanced
AUC-ROC	≥ 0.80	Mengukur kemampuan diskriminasi kelas model
Recall	≥ 0.75	Meminimalkan false negative (DM tidak terdeteksi)

1.5 Deskripsi Dataset

Dataset yang digunakan adalah **Pima Indians Diabetes Database** dari *National Institute of Diabetes and Digestive and Kidney Diseases* (NIDDK), USA. Seluruh subjek adalah perempuan berusia ≥ 21

tahun keturunan Pima Indian. Dataset ini bersifat publik dan dapat diakses melalui UCI Machine Learning Repository maupun Kaggle.

Jumlah Sampel	768 rekam medis
Jumlah Fitur Input	8 fitur numerik
Variabel Target	Outcome: 0 = Tidak Diabetes, 1 = Diabetes
Populasi	Perempuan ≥21 tahun, keturunan Pima Indian
Distribusi Kelas	500 Non-DM (65.1%) vs 268 DM (34.9%)
Sumber Data	UCI ML Repository / Kaggle / GitHub Brownlee

2 METODOLOGI

2.1 Alur Kerja (Pipeline)



2.2 Data Acquisition

Dataset diunduh secara programatik dari repositori publik GitHub menggunakan `urllib.request.urlretrieve()`. Verifikasi keaslian dilakukan dengan membandingkan statistik deskriptif dataset yang diunduh (768 baris, 9 kolom) dengan dokumentasi resmi UCI Machine Learning Repository. Data disimpan dalam format CSV dengan header yang informatif.

2.3 Exploratory Data Analysis (EDA)

a. Missing Values

Tidak ditemukan NaN eksplisit (`isnull().sum() = 0`). Namun, ditemukan **implicit missing values** berupa nilai 0 pada kolom-kolom yang secara medis tidak mungkin bernilai 0:

Kolom	Jumlah Nilai 0	Persentase	Keterangan
Glucose	5	0.7%	Kadar glukosa 0 tidak mungkin secara medis
BloodPressure	35	4.6%	Tekanan darah 0 tidak mungkin hidup
SkinThickness	227	29.6%	Data sering tidak diukur / tidak dicatat
Insulin	374	48.7%	Tertinggi — sering tidak terukur
BMI	11	1.4%	BMI 0 tidak mungkin pada individu hidup

b. Outlier Detection (IQR Method)

Outlier dideteksi menggunakan batas $1.5 \times \text{IQR}$. Kolom dengan outlier terbanyak: BloodPressure (45 outlier, 5.9%), Insulin (34, 4.4%), BMI (19, 2.5%), dan DiabetesPedigreeFunction (29, 3.8%). Outlier tidak dihapus karena merupakan nilai medis yang valid; ditangani oleh imputasi median yang robust terhadap outlier.

c. 5 Key Insights

- Insight 1 — Glukosa adalah Prediktor Terkuat:** Korelasi Pearson $r = 0.47$ — tertinggi dari semua fitur. Rata-rata glukosa DM 141 mg/dL vs Non-DM 110 mg/dL (selisih +28%).
- Insight 2 — BMI Tinggi Berkorelasi dengan Diabetes:** Rata-rata BMI DM = 35.1 vs Non-DM = 30.3. Korelasi $r = 0.29$. Obesitas ($\text{BMI} \geq 30$) merupakan faktor risiko signifikan.
- Insight 3 — Usia Berpengaruh:** Rata-rata usia DM = 37 tahun vs Non-DM = 31 tahun. Risiko meningkat progresif setelah usia 35 tahun ($r = 0.24$).

- **Insight 4 — Insulin Paling Banyak Hilang:** 48.7% nilai Insulin = 0 (tidak valid). Menunjukkan keterbatasan pengukuran di lapangan. Perlu imputasi hati-hati.
- **Insight 5 — Class Imbalance:** 65.1% Non-DM vs 34.9% DM. Ditangani dengan `class_weight="balanced"` dan pemilihan F1-Score sebagai metrik utama (bukan Accuracy).

2.4 Preprocessing

Langkah	Teknik	Justifikasi
1. Deteksi Missing Values	Nilai 0 → NaN (5 kolom)	Nilai 0 tidak mungkin secara medis pada fitur terpilih
2. Imputasi	Median per kelas (stratified)	Mempertahankan distribusi per kelas; robust terhadap outlier
3. Feature Engineering	4 fitur baru (category + ratio)	Informasi domain medis tambahan yang relevan secara klinis
4. Train/Val/Test Split	70/15/15 Stratified	Distribusi kelas terjaga di semua split; validasi tidak bias
5. Feature Scaling	StandardScaler (fit on train)	Scaler hanya di-fit pada training set — cegah data leakage

Feature Engineering Detail

Fitur Baru	Formula/Mapping	Dasar Medis
BMI_Category	0=Underweight(<18.5), 1=Normal, 2=Overweight, 3=Obese(≥30)	Kategori WHO standar untuk obesitas
Glucose_Category	0=Normal(<100), 1=Pre-DM(100-125), 2=DM(≥126 mg/dL)	Klasifikasi ADA (American Diabetes Association)
Age_Group	0=Young(<35), 1=Middle(35-50), 2=Senior(>50)	Risiko diabetes meningkat dengan usia
Insulin_Glucose_Ratio	Insulin / (Glucose + 1)	Proxy untuk resistensi insulin (konsep HOMA-IR)

2.5 Pemodelan

Tiga algoritma klasifikasi dibandingkan, dipilih berdasarkan karakteristik yang saling melengkapi:

Model	Tipe	Hyperparameter yang Di-tuning	Alasan Dipilih
Logistic Regression	Linear	C=[0.01,0.1,1,10,100], solver=[lbfgs, liblinear]	Baseline interpretable; koefisien menunjukkan arah pengaruh fitur
Random Forest	Ensemble (Bagging)	n_estimators=[100,200,300], max_depth=[None,10,20], class_weight	Robust terhadap overfitting; feature importance bawaan

Gradient Boosting	Ensemble (Boosting)	n_estimators=[100,200,300], learning_rate=[0.05,0.1,0.15], max_depth=[3,4,5]	State-of-the-art untuk tabular data; akurasi tinggi
--------------------------	----------------------	--	---

Hyperparameter Tuning: GridSearchCV dengan 5-fold Stratified K-Fold Cross-Validation, scoring = F1-Score, n_jobs=-1 (paralel semua core CPU). Total kombinasi: LR = 10, RF = 36, GB = 36 kombinasi.

2.6 Evaluasi

Evaluasi dilakukan pada ketiga split (train/validation/test) menggunakan 5 metrik utama:

Accuracy	Proporsi prediksi yang benar dari total prediksi: $(TP+TN)/(Total)$
Precision	Dari semua prediksi positif, berapa yang benar-benar positif: $TP/(TP+FP)$
Recall	Dari semua kasus positif nyata, berapa yang berhasil dideteksi: $TP/(TP+FN)$
F1-Score	Harmonic mean Precision dan Recall: $2 \times (Prec \times Rec) / (Prec + Rec)$
AUC-ROC	Area di bawah kurva ROC — mengukur kemampuan diskriminasi (0.5–1.0)

Kriteria pemilihan model terbaik: F1-Score tertinggi pada validation set. F1 dipilih karena menyeimbangkan Precision dan Recall — sangat penting dalam konteks medis di mana *false negative* (diabetes tidak terdeteksi) memiliki konsekuensi klinis yang serius.

3 HASIL DAN ANALISIS

3.1 Hasil EDA

Analisis korelasi Pearson menunjukkan bahwa **Glucose** ($r = 0.47$) memiliki korelasi tertinggi dengan Outcome, diikuti **BMI** ($r = 0.29$), **Age** ($r = 0.24$), **Pregnancies** ($r = 0.22$), dan **DiabetesPedigreeFunction** ($r = 0.17$). BloodPressure memiliki korelasi terendah ($r = 0.065$) dan tidak informatif secara individual. Dataset menunjukkan class imbalance 65:35 yang ditangani melalui `class_weight="balanced"` dan pemilihan F1-Score sebagai metrik.

3.2 Hasil Preprocessing

Setelah preprocessing, total NaN = 0 (seluruh nilai berhasil diimputasi). Distribusi kelas di semua split terjaga (stratified): Train 70—Val 15—Test 15 (536—116—116 sampel). Fitur bertambah dari 8 menjadi **12 fitur** setelah feature engineering. Semua fitur berhasil dinormalisasi dengan StandardScaler (mean ≈ 0 , std ≈ 1 pada training set).

3.3 Hasil Training & Hyperparameter Tuning

Model Terbaik	Gradient Boosting (berdasarkan F1 tertinggi pada Val Set)
Best Params	<code>learning_rate=0.05, max_depth=3, n_estimators=100, subsample=1.0</code>
5-Fold CV F1	0.8166 (pada training set)
F1 Validation	0.8571
F1 Test	0.8537

Hyperparameter Terbaik Semua Model

Model	Hyperparameter Terbaik	CV F1 Score
Logistic Regression	<code>C=0.01, solver='liblinear', max_iter=2000</code>	0.7104
Random Forest	<code>class_weight='balanced', max_depth=None, n_estimators=200, min_samples_leaf=2</code>	0.8447
Gradient Boosting ★	<code>learning_rate=0.05, max_depth=3, n_estimators=100, subsample=1.0</code>	0.8166

3.4 Perbandingan Metrik Semua Model (Train / Val / Test)

Model	Set	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Logistic Regression	Train	0.7966	0.7097	0.7059	0.7078	0.8766
	Val	0.7931	0.6889	0.7561	0.7209	0.8618
	Test	0.7586	0.6250	0.7500	0.6818	0.8283
Random Forest	Train	0.9739	0.9347	0.9947	0.9637	0.9993

	Val	0.8793	0.8000	0.8780	0.8372	0.9480
	Test	0.8793	0.7955	0.8750	0.8333	0.9482
Gradient Boosting	Train	0.9496	0.9255	0.9305	0.9280	0.9928
	Val	0.8966	0.8372	0.8780	0.8571	0.9486
	Test	0.8966	0.8333	0.8750	0.8537	0.9582


Analisis: Gradient Boosting mencapai performa terbaik di semua metrik pada test set. Perlu dicatat bahwa Random Forest menunjukkan gap train-test yang lebih besar (train F1 = 0.9637 vs test = 0.8333), mengindikasikan sedikit overfitting. Gradient Boosting memiliki keseimbangan yang lebih baik (train F1 = 0.9280 vs test = 0.8537). Semua target metrik **terlampai**: Acc ≥ 0.75 ✓, F1 ≥ 0.70 ✓, AUC ≥ 0.80 ✓, Recall ≥ 0.75 ✓.

3.5 Feature Importance Analysis


Berdasarkan analisis feature importance dari ketiga model, urutan kepentingan fitur yang konsisten adalah sebagai berikut:

- **Glucose** — Prediktor terkuat secara konsisten di semua model. Kadar glukosa tinggi merupakan indikator utama diabetes mellitus.
- **BMI** — Faktor risiko obesitas sangat berpengaruh. BMI tinggi berkaitan erat dengan resistensi insulin.
- **Age** — Risiko meningkat progresif. Model menangkap non-linearitas pengaruh usia yang tidak terlihat dari korelasi linear saja.
- **DiabetesPedigreeFunction** — Riwayat keluarga diabetes merupakan faktor risiko genetik yang signifikan.
- **Glucose_Category** (fitur baru) — Kategorisasi ADA memberikan informasi tambahan yang meningkatkan discriminability model.
- **Pregnancies** — Riwayat gestational diabetes berkorelasi dengan risiko DM tipe 2 di kemudian hari.


3.6 Visualisasi




Gambar 3.1 — Distribusi Kelas Target (Bar Chart & Pie Chart)




Gambar 3.2 — Perbandingan Performa Model (Test Set)




Gambar 3.3 — ROC Curves Semua Model



Gambar 3.4 — Confusion Matrix Semua Model



Gambar 3.5 — Feature Importance Semua Model



Gambar 3.6 — Correlation Heatmap Dataset

4 KESIMPULAN DAN REKOMENDASI

4.1 Kesimpulan

- **Semua target metrik berhasil dicapai oleh model Gradient Boosting pada test set:** Accuracy = 0.8966 ($\geq 75\%$), F1-Score = 0.8537 (≥ 0.70), AUC-ROC = 0.9582 (≥ 0.80), Recall = 0.8750 (≥ 0.75). Model terbukti efektif untuk tugas klasifikasi biner deteksi diabetes.
- **Glucose dan BMI adalah prediktor terkuat** secara konsisten di semua model. Intervensi klinis yang fokus pada dua faktor ini (pemantauan gula darah dan pengendalian berat badan) akan paling efektif dalam pencegahan diabetes.
- **Gradient Boosting unggul** dalam menyeimbangkan Precision (0.8333) dan Recall (0.8750), menjadikannya pilihan optimal untuk konteks medis di mana false negative harus diminimalkan.
- **Pipeline Machine Learning end-to-end** berhasil dibangun mencakup seluruh tahap: akuisisi data, EDA, preprocessing, pemodelan, evaluasi, dan deployment sebagai aplikasi web interaktif Streamlit dengan 6 halaman lengkap.
- **Feature engineering berbasis domain medis** (kategorisasi BMI, Glucose, Age sesuai standar WHO dan ADA) terbukti meningkatkan performa model dibanding menggunakan 8 fitur original saja.
- **Aplikasi web DiabetesSense** berhasil dikembangkan dan siap digunakan sebagai alat bantu skrining awal diabetes yang mudah diakses oleh tenaga medis maupun masyarakat umum.

Metrik	Target	Hasil (GB Test)	Status
Accuracy	$\geq 75\%$	0.8966	✓ TERCAPAI
F1-Score	≥ 0.70	0.8537	✓ TERCAPAI
AUC-ROC	≥ 0.80	0.9582	✓ TERCAPAI
Recall	≥ 0.75	0.8750	✓ TERCAPAI

4.2 Rekomendasi

a. Rekomendasi Klinis / Bisnis

- Implementasikan sistem skrining ML ini di puskesmas dan klinik endokrinologi untuk triase pasien berisiko tinggi.
- Tetapkan threshold prediksi ≥ 0.40 (bukan default 0.50) untuk meminimalkan false negative dalam konteks klinis.
- Prioritaskan pemeriksaan Glucose darah dan pengukuran BMI pada setiap kunjungan pasien sebagai indikator risiko utama.
- Integrasikan sistem ini dengan Electronic Health Record (EHR) yang sudah berjalan untuk workflow tanpa gangguan.
- Jalankan program edukasi masyarakat tentang pentingnya pemantauan kadar gula darah, terutama untuk kelompok usia >35 tahun dengan BMI tinggi.

b. Rekomendasi Pengembangan Teknis

- Tambahkan fitur HbA1c, kolesterol total, dan riwayat keluarga yang lebih detail untuk meningkatkan akurasi.
- Implementasikan SMOTE (Synthetic Minority Over-sampling Technique) untuk mengatasi class imbalance secara lebih agresif.
- Eksplorasi XGBoost, LightGBM, CatBoost, dan ensemble stacking untuk performa yang lebih baik.
- Gunakan SHAP (SHapley Additive exPlanations) untuk interpretabilitas model yang lebih mendalam dan dapat dipercaya secara klinis.
- Validasi model pada dataset yang lebih besar dan populasi yang lebih beragam (bukan hanya Pima Indian).
- Deploy ke cloud platform (Streamlit Community Cloud, Google Cloud Run, atau AWS) untuk aksesibilitas yang lebih luas.

4.3 Keterbatasan

- Dataset terbatas (768 sampel) dari populasi yang sangat spesifik (perempuan Pima Indian ≥ 21 tahun) — generalisasi ke populasi lain perlu validasi.
- Sebanyak 48.7% nilai Insulin kosong (nilai 0 tidak valid) — imputasi median merupakan approximation terbaik yang tersedia.
- Fitur penting secara klinis (HbA1c, kolesterol, gaya hidup, pola makan) tidak tersedia dalam dataset ini.
- Model belum divalidasi secara prospektif pada pasien nyata di fasilitas kesehatan.

5 REFERENSI

- [1] Smith, J.W., Everhart, J.E., Dickson, W.C., Knowler, W.C., & Johannes, R.S. (1988). *Using the ADAP learning algorithm to forecast the onset of diabetes mellitus*. Proceedings of the Annual Symposium on Computer Application in Medical Care, 261–265.
- [2] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [3] International Diabetes Federation. (2021). *IDF Diabetes Atlas, 10th Edition*. Brussels, Belgium: IDF. <https://diabetesatlas.org>
- [4] Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [5] Friedman, J.H. (2001). *Greedy Function Approximation: A Gradient Boosting Machine*. The Annals of Statistics, 29(5), 1189–1232.
- [6] Hosmer, D.W., & Lemeshow, S. (2000). *Applied Logistic Regression (2nd ed.)*. New York: John Wiley & Sons.
- [7] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R (2nd ed.)*. New York: Springer. <https://www.statlearning.com>
- [8] Streamlit Inc. (2024). *Streamlit — The fastest way to build data apps*. Retrieved from <https://streamlit.io>
- [9] Kementerian Kesehatan RI. (2018). *Hasil Utama Riset Kesehatan Dasar (Riskesdas) 2018*. Badan Penelitian dan Pengembangan Kesehatan.
- [10] American Diabetes Association. (2023). *Standards of Medical Care in Diabetes 2023*. Diabetes Care, 46(Supplement 1).
- [11] Lundberg, S.M., & Lee, S.I. (2017). *A unified approach to interpreting model predictions*. Advances in Neural Information Processing Systems, 30, 4765–4774.
- [12] WHO. (2023). *Obesity and overweight*. WHO Fact Sheet. <https://www.who.int/news-room/fact-sheets/detail/obesity-and-overweight>

Laporan ini disusun untuk memenuhi persyaratan Ujian Akhir Semester (UAS) Mata Kuliah Pembelajaran Mesin, Semester Genap 2025/2026, Universitas Dian Nuswantoro (UDINUS) Semarang.